# CUANDO LA MÁQUINA APRENDE A LEER

**Etiquetado de datos, visión por computadora y el reto de la precisión**

## ¿Cómo "ve" una máquina?

Un ingeniero humano mira una resistencia y, en menos de un segundo, lee sus bandas de colores, calcula el valor y verifica la tolerancia. Para una computadora, ese proceso es extraordinariamente complejo.

Para empezar, una computadora **no ve una resistencia**. Ve una matriz de números. Cuando una cámara captura una imagen, la divide en miles o millones de **píxeles**. Cada píxel tiene tres valores numéricos **entre 0 y 255**: cuánto rojo, cuánto verde y cuánto azul contiene. Eso es el famoso **modelo RGB**. Así, el rojo puro se representa como **(255, 0, 0)**; el negro, como **(0, 0, 0)**; y el blanco, como **(255, 255, 255)**.

Fíjate en el contraste: en el código de colores de las resistencias, cada banda vale entre **0 y 9** (un solo dígito). En el modelo RGB, cada color vale entre **0 y 255**. Cada sistema de codificación elige su rango según lo que necesita representar.

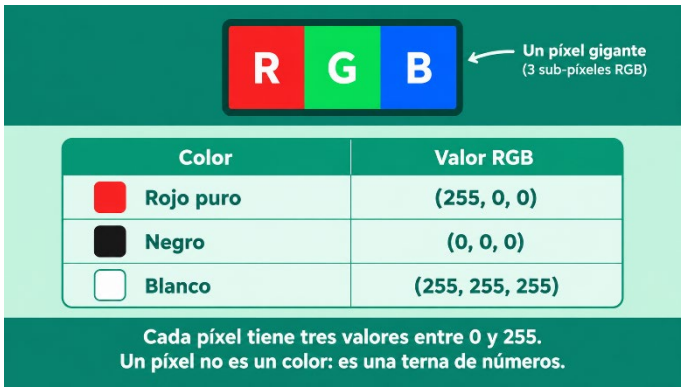



*Fig. 1: Un píxel no es un color: es una terna de tres números entre 0 y 255. El rojo puro se escribe (255, 0, 0); el negro, (0, 0, 0).*

💡 **Idea clave:** para la máquina, una resistencia no es un objeto físico: es una **matriz de números**. El trabajo de la visión por computadora es encontrar patrones en esa matriz. El código de colores es justamente un patrón.

### 🎨 Del color al número: el puente que ya conoces

El código de colores **convierte colores en valores numéricos**. Una máquina necesita hacer exactamente lo mismo, pero al revés: convertir una imagen en valores numéricos.

El proceso es sorprendentemente similar al que hace un estudiante con una tabla de colores:

1. **Captura:** la cámara convierte la luz reflejada por la resistencia en una matriz de números (RGB).
2. **Detección:** el sistema identifica la región de la imagen donde está la resistencia (separándola del fondo).
3. **Segmentación:** localiza las bandas de color dentro de esa región.
4. **Clasificación:** asigna cada banda a una categoría (rojo, naranja, marrón…).
5. **Cálculo:** aplica la misma fórmula que usaría un humano: dígitos × multiplicador ± tolerancia.

Cada uno de esos pasos es un problema de ingeniería. Y todos ellos dependen de un ingrediente fundamental: **datos de entrenamiento**. Sin ejemplos previos, la máquina no sabe qué es "rojo" ni qué es "una banda".




*Fig. 2: El proceso completo, paso a paso. Cada etapa es un problema de ingeniería, y todas dependen de los datos de entrenamiento.*

### 🧠 Dos formas de resolver el mismo problema

Antes de seguir, hay una distinción clave que conviene aclarar. Existen dos maneras muy distintas de lograr que una máquina lea una resistencia:

- **Reglas explícitas (enfoque tradicional):** un ingeniero escribe la regla directamente. *"Si la banda es roja, vale 2. Si es marrón, vale 1. Si es dorada, la tolerancia es ±5%."* Es el mismo enfoque que tú usas cuando consultas una tabla de colores.
- **Aprendizaje automático (IA):** el modelo **descubre la regla por sí mismo** a partir de miles de ejemplos. No le decimos "el rojo vale 2". Le mostramos miles de resistencias ya etiquetadas, y el modelo aprende solo qué colores corresponden a qué valores.

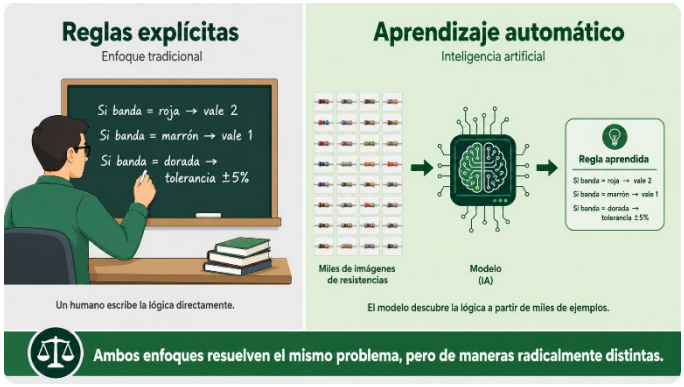



*Fig. 3: Dos caminos para resolver el mismo problema. A la izquierda, el ingeniero escribe las reglas. A la derecha, el modelo las descubre a partir de ejemplos.*

💡 **La diferencia es enorme:** con reglas explícitas, tú (el ingeniero) escribes la lógica. Con aprendizaje automático, la máquina *infiere* la lógica. La consecuencia práctica es que el aprendizaje automático requiere **muchos datos** y **mucho entrenamiento**, pero permite resolver problemas que serían imposibles de programar con reglas fijas (como reconocer un rostro o leer una señal de tránsito).

### 🔗 Una conexión directa

El código de colores es, en esencia, un **sistema de etiquetado creado por humanos**. Los ingenieros asignaron un número a cada color y acordaron usarlo en todo el mundo. Ahora le pedimos a la IA que haga lo mismo: que aprenda a "etiquetar" colores con valores. Estás viendo la misma idea, casi 100 años después.

---

## 2. Etiquetado de datos: el arte de enseñar a una máquina

Antes de que una IA pueda leer resistencias, necesita aprender qué son. Y para aprender, necesita ejemplos. Muchos ejemplos. Miles o millones. Pero no basta con darle imágenes al azar: hay que **etiquetarlas**.

El **etiquetado de datos** (en inglés, *data labeling*) es el proceso de asignar una etiqueta a cada elemento de un **conjunto de datos** (en inglés, *dataset*). Es el trabajo que permite que una máquina aprenda a reconocer patrones.

💡 **Ejemplo:** si queremos entrenar una IA para leer resistencias, necesitamos:

- Miles de fotos de resistencias con distintas iluminaciones, ángulos, fondos y desgastes.

- Cada foto etiquetada manualmente por un humano: *"Esta foto muestra una resistencia de 330 Ω ±5%"*.
- Muchas fotos por cada valor y cada combinación de colores posible.

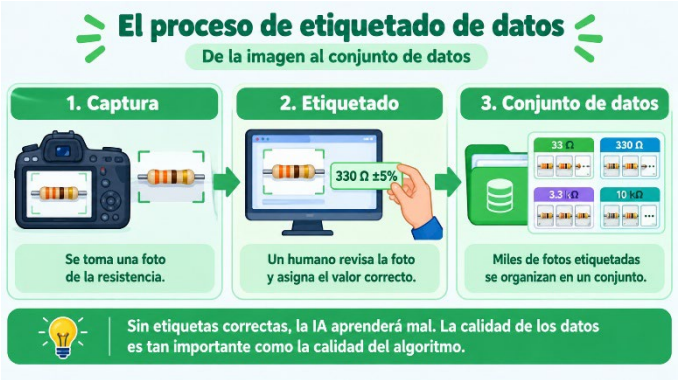



*Fig. 4: El proceso de etiquetado, paso a paso. Cada foto requiere una etiqueta correcta para que la IA pueda aprender.*

### 🎯 ¿Por qué la precisión de la etiqueta es tan importante?

Aquí hay un principio fundamental: **la calidad de una IA depende de la calidad de sus datos**. Si las etiquetas están mal, la IA aprenderá mal. Es el famoso principio de *"basura entra, basura sale"*.

Imagina que etiquetas mal una foto: dices que muestra "330 Ω" cuando en realidad muestra "33 Ω". La IA aprenderá que los patrones visuales de esas dos resistencias son iguales. Y cuando le muestres una nueva foto, se equivocará.

💡 **Comparación con el código de colores:** cuando un estudiante lee mal una banda (por ejemplo, confunde el rojo con el marrón), obtiene un valor equivocado. Lo mismo le pasa a una IA cuando su etiqueta está mal. La diferencia es que el estudiante puede darse cuenta del error y corregirlo; la IA no.

### ⚖️ El sesgo: cuando los datos no representan la realidad

Hay un problema que aparece una y otra vez en el entrenamiento de IA, y que conviene entender bien: el **sesgo** (en inglés, *bias*). Un modelo sesgado es un modelo que funciona bien en ciertas condiciones, pero falla en otras.

En el caso de las resistencias, el sesgo puede tomar varias formas:

- **Sesgo de iluminación:** si todas las fotos se tomaron con luz blanca, la IA fallará cuando vea una resistencia bajo luz amarilla.
- **Sesgo de estado:** si todas las resistencias eran nuevas y limpias, la IA no reconocerá las viejas y desgastadas.
- **Sesgo de marca:** si todas las fotos eran del mismo fabricante, la IA podría confundir variaciones de diseño con valores distintos.

En todos los casos, el problema es el mismo: **la IA hereda los sesgos de sus datos**. Un conjunto de datos diverso produce un modelo robusto; un conjunto de datos sesgado produce un modelo frágil.




*Fig. 5: Un conjunto sesgado produce un modelo frágil. Un conjunto diverso produce un modelo robusto, capaz de reconocer la realidad en todas sus variaciones.*

💡 **Más allá de las resistencias:** el sesgo es uno de los problemas más importantes de la IA actual. Una IA médica entrenada solo con datos de un grupo étnico puede fallar en otros. Una IA de contratación entrenada con datos históricos sesgados puede perpetuar discriminaciones. La **diversidad de los datos** no es un detalle técnico: es una responsabilidad ética.

🌎 **El trabajo invisible detrás de la IA**

Detrás de cada modelo de visión por computadora hay miles de horas de trabajo humano etiquetando datos. Personas que, foto por foto, dibujan cajas sobre los objetos, asignan categorías y verifican resultados. Es un trabajo silencioso pero fundamental.

Y ese trabajo también tiene un componente ético: quien etiqueta decide qué es importante y qué no. Un sesgo en las etiquetas se convierte en un sesgo en la IA.

---

### 3. Visión por computadora: del píxel a la decisión

La **visión por computadora** es la rama de la inteligencia artificial que permite a las máquinas "ver" e interpretar imágenes. Es la tecnología que usan los carros autónomos, los sistemas de reconocimiento facial y las cámaras de seguridad inteligentes.

🧠 **¿Cómo funciona?**

Un modelo de visión por computadora se entrena con miles de imágenes etiquetadas. A lo largo del entrenamiento, el modelo aprende a **extraer características** de las imágenes: bordes, formas, texturas, colores. Esas características se combinan en capas cada vez más abstractas, hasta que el modelo puede reconocer objetos completos.

💡 **Ejemplo concreto:** una IA entrenada para leer resistencias aprende, primero, a detectar *bordes* (los límites de las bandas). Luego, a detectar *colores* (el rojo, el naranja, el marrón). Finalmente, a detectar *patrones completos* (una resistencia con banda dorada al final significa tolerancia ±5%).

📊 **La IA no sabe, estima: confianza y probabilidad**

Aquí hay una diferencia fundamental entre una máquina y un humano. Cuando tú miras una resistencia y dices *"esto es 330 Ω"*, lo dices con certeza. Pero cuando una IA analiza la misma resistencia, no dice *"esto es 330 Ω"*: dice, por ejemplo, *"hay 92% de probabilidad de que esto sea 330 Ω"*.

Esa probabilidad se llama **confianza** del modelo. Es un número entre 0 y 1 (o entre 0% y 100%) que indica qué tan seguro está el modelo de su respuesta.




*Fig. 6: La IA no dice "esto es 330 Ω". Dice "hay X% de probabilidad de que esto sea 330 Ω". La confianza indica qué tan seguro está el modelo.*

💡 **¿Por qué es importante?** Porque un modelo bien entrenado tiene *alta confianza cuando acierta* y *baja confianza cuando duda*. Si un sistema de seguridad lee "92% resistencias" pero "20% posibles explosivos", sabemos que necesita más datos antes de actuar. La confianza permite tomar decisiones informadas.

### ⚖️ Los retos de la visión artificial

A diferencia de un humano, una IA no "entiende" lo que ve. Solo reconoce patrones. Eso la hace vulnerable a varios problemas:

- **Iluminación:** una resistencia fotografiada con luz amarilla puede verse distinta que con luz blanca. La IA debe aprender a ser invariante a la iluminación.
- **Ángulo:** una resistencia fotografiada desde un ángulo extraño puede confundir al modelo.
- **Desgaste:** una resistencia vieja y sucia puede tener los colores alterados. La IA debe aprender a reconocer el patrón incluso con ruido.
- **Falsos positivos:** la IA puede "ver" resistencias donde no las hay, o confundir componentes similares.

Por eso el entrenamiento con datos diversos es tan importante: la IA debe ver la realidad en todas sus variaciones para poder reconocerla cuando la encuentre.

---

### La precisión de la etiqueta: el nuevo código de colores

Una resistencia no vale exactamente 330 Ω: vale *aproximadamente* 330 Ω. La diferencia entre el valor ideal y el valor real se llama **tolerancia**, y es un **margen de error aceptable**. En inteligencia artificial existe un concepto paralelo: la **precisión de la etiqueta**.

Así como una resistencia de 330 Ω ±5% puede valer entre 313,5 Ω y 346,5 Ω, una etiqueta también tiene un margen de error. Si el etiquetador se equivoca en un 1% de las imágenes, la IA aprenderá con ese 1% de ruido. El resultado no será perfecto, pero puede ser aceptable.

💡 **Comparación:** la tolerancia en resistencias y la precisión en etiquetas siguen el mismo principio de ingeniería: *no se busca la perfección absoluta, sino un margen de error controlado*. En ambos casos, asumir que algo puede fallar es lo que permite diseñar sistemas robustos.

### 🎯 Métricas de evaluación

Para medir qué tan bien funciona una IA, se usan varias métricas:

- **Exactitud** (en inglés, *accuracy*): el porcentaje de aciertos sobre el total. Si la IA lee bien 950 de 1000 resistencias, su exactitud es del 95%.
- **Precisión** (en inglés, *precision*): de todas las resistencias que la IA dijo que eran de 330 Ω, ¿cuántas realmente lo eran?
- **Sensibilidad** (en inglés, *recall*): de todas las resistencias de 330 Ω que existían, ¿cuántas detectó la IA?

Cada métrica captura un aspecto distinto del rendimiento. Un buen ingeniero de IA no se fija solo en una: las combina para tener una visión completa.

### 🌎 La dimensión ética

Cuando una IA se equivoca, las consecuencias dependen del contexto. Si una IA de laboratorio lee mal una resistencia, el peor caso es un circuito que no funciona. Pero si una IA médica se equivoca al leer una radiografía, o una IA de tráfico no reconoce un peatón, las consecuencias son graves.

Por eso la **precisión de las etiquetas** no es un detalle técnico: es una responsabilidad. Quien entrena una IA debe asegurarse de que los datos sean correctos, diversos y representativos de la realidad.

---

## 🤌 Taller: Entrena a tu propia IA

Vas a experimentar el proceso de **etiquetado de datos** desde dentro. La misión es crear un **mini conjunto de datos** de resistencias que podría usarse para entrenar una IA.

💡 **Dos formas de hacer este taller:** puedes hacerlo en el aula (con resistencias del kit y un celular para fotos) o llevarlo a casa si tienes acceso a un dispositivo con cámara. Si no tienes cámara, puedes hacer una versión simplificada dibujando las resistencias.

### 🧰 Materiales

- Cinco resistencias de valores distintos.
- Un celular con cámara (o un dispositivo con cámara).
- Una hoja de papel blanco como fondo.
- Una lámpara o fuente de luz (opcional, para variar la iluminación).
- Tu cuaderno de bitácora.

### 🛠️ Procedimiento

1. **Prepara el escenario.** Coloca las resistencias sobre el papel blanco, separadas entre sí.
2. **Toma fotos.** Captura al menos tres fotos de cada resistencia:
    - Una con buena iluminación.
    - Una con luz tenue o lateral.
    - Una desde un ángulo distinto.
3. **Etiqueta cada foto.** En tu cuaderno, anota para cada foto:
    - El número de foto (1, 2, 3…).
    - El valor de la resistencia que aparece.
    - Las condiciones de la foto (buena luz, luz tenue, ángulo).
4. **Crea una tabla de etiquetas.** Completa esta tabla en tu bitácora:

| *# Foto* | *Resistencia* | *Valor* | *Tolerancia* | *Condiciones* |
|---|---|---|---|---|
| *1* | | | | |
| *2* | | | | |
| *3* | | | | |
| *4* | | | | |
| *5* | | | | |
| *6* | | | | |
| *7* | | | | |
| *8* | | | | |

5. **Reflexiona sobre la diversidad del conjunto de datos.** ¿Cuántas combinaciones distintas de colores y condiciones lograste? ¿Qué variables podrían agregarse para hacer un conjunto de datos más completo?
6. **Detecta los errores.** Si tuvieras que pedirle a otra persona que etiquetara las fotos por ti, ¿qué instrucciones le darías para minimizar los errores? Escribe al menos tres reglas claras.
7. **Analiza el sesgo.** Revisa tu conjunto de datos: ¿todas las fotos son de resistencias nuevas? ¿Todas se tomaron con la misma luz? ¿Todas desde el mismo ángulo? Anota al menos un sesgo que tenga tu conjunto de datos y cómo podrías corregirlo.

### 📝 Mi nota sobre el taller

Cuando termines, escribe **una nota breve** al final de tu hoja de registro. No es una tarea, es una reflexión. Puedes escribir sobre:

- ¿Qué fue más difícil: tomar las fotos, etiquetarlas o encontrar la diversidad?
- ¿Qué foto crees que sería más difícil para una IA? ¿Por qué?
- Si tuvieras que entrenar una IA con solo 10 fotos, ¿cuáles elegirías y por qué?
- ¿Qué sesgos tiene tu conjunto de datos y cómo podrías corregirlos?

### ❓ Pregunta guía

Un conjunto de datos con 10,000 fotos de resistencias etiquetadas por humanos puede entrenar una IA para leer resistencias. Pero ¿qué pasaría si todas las fotos tuvieran la misma iluminación? ¿Qué pasaría si todas fueran de la misma marca? ¿Qué problemas tendría esa IA en el mundo real?

💡 **¿Sabías que…?** Algunos de los conjuntos de datos más grandes de visión por computadora tienen más de 14 millones de imágenes etiquetadas. Y cada una fue anotada por una persona. Detrás de cada IA hay un trabajo humano enorme, a menudo invisible.

⚠️ **Seguridad:** si usas un celular para tomar las fotos, no expongas la pantalla a golpes ni la mojes. Y si usas resistencias dentro de un aparato, primero desconecta el aparato y retira las pilas.

---

### 📜 Cápsula histórica: La mujer que enseñó a las máquinas a ver

Durante décadas, la visión por computadora fue un campo pequeño y frustrante. Los investigadores lograban avances, pero los modelos fallaban en el mundo real. Nadie sabía por qué. Hasta que una investigadora se dio cuenta de que el problema no era el algoritmo: era la falta de datos.

### 👩‍🏫 Fei-Fei Li (1976) — La madrina de la visión por computadora

Fei-Fei Li nació en China y emigró a Estados Unidos a los 16 años. Trabajó en empleos humildes mientras estudiaba, y llegó a ser profesora de ciencias de la computación en Stanford. Cuando empezó a investigar visión por computadora, el campo estaba estancado.

En 2007, Li tuvo una idea que muchos consideraron una locura: en lugar de mejorar los algoritmos, **recolectar un conjunto de datos gigantesco de imágenes etiquetadas**. Creó **ImageNet**, un proyecto que reúne millones de fotos, cada una etiquetada por un humano. Ella y su equipo no mejoraron el algoritmo: cambiaron los datos.

El resultado fue transformador. En 2012, un modelo entrenado sobre ImageNet (llamado **AlexNet**) arrasó en una competencia internacional de reconocimiento de imágenes. La visión por computadora dio un salto cuántico, y desde entonces todos los grandes avances de la IA moderna han descansado sobre conjuntos de datos masivos.

### 🌎 De ImageNet a ChatGPT

El principio que Fei-Fei Li demostró con ImageNet se aplica hoy a todos los modelos de IA, incluidos los que generan texto o imágenes. La calidad de un modelo depende de la calidad y la cantidad de sus datos de entrenamiento. Los "modelos gigantes" como

ChatGPT deben su poder, en gran medida, a la enorme cantidad de texto con el que fueron entrenados.

Y detrás de cada conjunto de datos hay miles de personas etiquetando, revisando y corrigiendo. Es el trabajo silencioso que sostiene toda la inteligencia artificial moderna.

**La lección:** a veces la innovación no está en mejorar el algoritmo, sino en **cambiar los datos**. Fei-Fei Li no resolvió el problema de la visión por computadora con una fórmula mágica: lo resolvió con millones de ejemplos etiquetados. Y eso cambió la historia de la IA.

*Fuentes: archivos históricos de ImageNet y biografías de la Universidad de Stanford.*

---

### 🗺️ Repaso visual

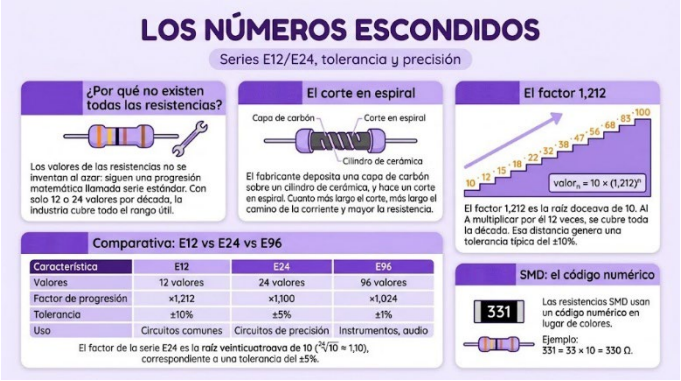



*Fig. 7: Cuando la máquina aprende a leer. Infografía que sintetiza el proceso de etiquetado de datos, cómo una IA procesa una imagen de resistencia y los retos de la visión por computadora.*

**Tu mapa completo:** esta infografía resume los temas que acabas de recorrer: cómo ve una máquina, el etiquetado de datos, la visión por computadora y la precisión de las etiquetas. ¿Reconoces cada parte? ¿Cuál te resultó más útil?

---

🎧 Audio-Guía · Episodio 4: **Cuando la máquina aprende a leer**

**Dale play** y en 7 minutos descubrirás:

- 👁️ **Cómo ve una máquina:** por qué una imagen es solo una matriz de números RGB.
- 🧠 **Reglas vs. aprendizaje:** por qué la IA descubre la regla en lugar de recibirla escrita.
- 🏷️ **Etiquetado de datos:** el arte de enseñar a una máquina con ejemplos etiquetados.
- ⚖️ **El sesgo:** cómo los datos sesgados producen modelos frágiles y poco confiables.
- 📊 **La IA no sabe, estima:** confianza, probabilidad y verdad fundamental.
- 👩‍💻 **Fei-Fei Li e ImageNet:** la mujer que cambió la IA al cambiar los datos.

💡 **Escúchenlo en familia y comenten qué otras tareas hacen las máquinas hoy que antes solo hacían los humanos.**

---

### 🧠 Cierre: pensar como ingeniero de IA

Responde en tu cuaderno:

1. ¿Por qué una computadora necesita "traducir" una imagen a números para poder procesarla?
2. ¿Cuál es la diferencia entre un sistema de reglas explícitas y un modelo de aprendizaje automático?
3. ¿Qué es el **etiquetado de datos** y por qué es fundamental para entrenar una IA?
4. ¿Qué es el **sesgo** en un conjunto de datos y cómo puede afectar el rendimiento de una IA?

5. ¿Por qué decimos que "la IA no sabe, estima"? Explica el concepto de **confianza**.
6. ¿Qué pasaría si un conjunto de datos de resistencias tuviera todas las fotos con la misma iluminación?
7. ¿Cómo se relaciona la tolerancia de una resistencia con la precisión de una etiqueta?
8. ¿Por qué la calidad de los datos es tan importante como la calidad del algoritmo?
9. ¿Qué responsabilidad tienen las personas que etiquetan datos para una IA?
10. ¿Qué aprendiste de la historia de Fei-Fei Li y su trabajo con ImageNet?
11. ¿Qué parte de la infografía te resultó más útil como repaso? ¿Por qué?

---

### 📚 Fuentes consultadas

- Archivos históricos del proyecto ImageNet.
- Biografías de la Universidad de Stanford.
- Documentación técnica sobre visión por computadora y etiquetado de datos.

---

💡 **Sugerencia:** si te da curiosidad cómo abordan el mismo tema tus compañeros de otros grados, visita al menos una de las otras miradas. Cada una revela algo que las demás no.

---

### 📚 Fuentes consultadas

- Archivos históricos de la Comisión Electrotécnica Internacional (IEC).
- Norma internacional IEC 60063 (series de valores estándar).
- Biografías de Charles Renard.

---

### 🔗 Explora otras miradas del mismo fenómeno

**Sugerencia:** si te da curiosidad cómo abordan el mismo tema tus compañeros de otros grados, visita al menos una de las otras miradas. Cada una revela algo que las demás no.

- 🟠 Mirada curiosa (Grado 6°): El lenguaje de las rayitas.
- 🔵 Mirada comparativa (Grado 7°): Códigos que ya conoces.
- 🟣 Mirada estructural (Grado 8°): Los números escondidos.

---